Система для анализа библиометрических показателей CEUR Workshop Proceedings

Шитов Егор Александрович Научный руководитель: Чернышев Георгий Алексеевич

СПбГУ, Математико-механический факультет Системное программирование

Цели и задачи

Цель — разработать систему для анализа библиометрических показателей открытого репозитория CEUR-WS. Задачи, поставленные в рамках данной работы:

- реализовать забор данных с сайта
- разработать схему хранения данных в БД
- · извлекать информацию из pdf файла статьи
- реализовать модуль дедупликации статей
- реализовать пользовательский интерфейс

Существующие решения

- ACM Digital Library
- Springer Link
- · IEEE Xplore Digital Library
- DBLP

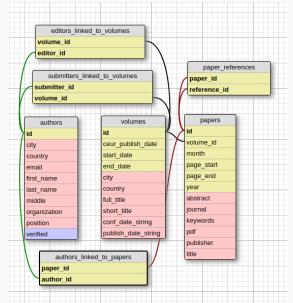
Выбор технологий

- Kotlin
- Golang
- Spring Boot
- · MySQL
- Freemarker

Архитектура

- трехуровневая
- модульная
 - отказоустойчивость
 - легкость замены модулей
 - распределение нагрузки

Структура базы данных



Парсеры ссылок на статьи

- AnyStyle
- FreeCite
- · GROBID

Дедупликация (

- сравнить года публикации
- сравнить авторов по инициалам
- сравнить названия статей

Итоги

- реализован забор данных с сайта CEUR-WS.org
- организовано хранение данных в БД
- найден и использован эффективный инструмент для извлечения информации из pdf файла статьи
- реализован модуль дедупликации статей
- реализован базовый пользовательский интерфейс