Поиск ошибок в коде при помощи глубокого обучения в IntelliJ IDEA

Тучина Анастасия Игоревна 343 группа

научный руководитель: к.т.н., доцент Т.А.Брыксин

СПбГУ

Актуальность

- Большое количество видов ошибок
- Большое количество инструментов и подходов
- На ранних стадиях разработки при использовании динамически типизированных языков часть ошибок остается незамеченной
- Современные решения:
 - Статические анализаторы кода (Google Error Prone, FindBugs)
 - Анализ графов потока управления
 - Поиск известных паттернов ошибок

DeepBugs Framework

DeepBugs — инструмент, который:

- Легко расширять на новые классы ошибок
- Использует максимально возможное количество информации из кода (например, имена переменных)

Michael Pradel and Koushik Sen, 2018, DeepBugs: A Learning Approach to Name-Based Bug Detection. In Proceedings of the ACM on Programming Languages Volume 2 Issue OOPSLA, November 2018

Постановка задачи

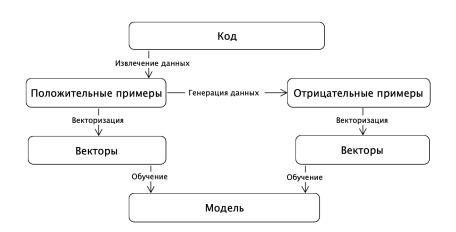
Цель:

• Создание и интеграция детектора ошибок DeepBugs с IntelliJ Platform

Задачи:

- Реализация инспекций кода на JavaScript с использованием предложенных моделей
- Адаптация предложенного подхода для Python с использованием Intellij SDK
- Обучение детектора ошибок для каждого из выбранных паттернов
- Реализация инспекций кода на Python, задействующих полученные модели

Архитектура детектора



Представление данных

- Бинарная операция:
 - $(n_{left}, n_{right}, op, t_{left}, t_{right}, k_{parent}, k_{grandP})$
- Вызов функции, принимающей два аргумента:

```
(n_{base},\,n_{callee},\,n_{arg_1},\,n_{arg_2},\,t_{arg_1},\,t_{arg_2},\,n_{param_1},\,n_{param_2})
```

Генерация данных

Детектор неправильного порядка аргументов в вызове функции

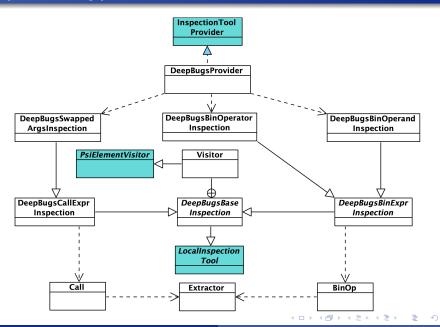
- Положительный пример: $(n_{base}, n_{callee}, n_{arq_1}, n_{arq_2}, t_{arq_1}, t_{arq_2}, n_{param_1}, n_{param_2})$
- Отрицательный пример: $(n_{base}, n_{callee}, n_{ara_2}, n_{ara_1}, t_{ara_2}, t_{ara_1}, n_{param_1}, n_{param_2})$

```
4 D > 4 B > 4 B > 4 B > 9 Q O
```

Векторизация фрагментов кода

- Каждый из операторов закодирован с помощью one-hot encoding
- Каждый тип данных закодирован с помощью уникального случайного бинарного вектора длины 5
- Каждый тип узла AST закодирован с помощью уникального случайного бинарного вектора длины 8
- Имена идентификаторов векторизуются с помощью Word2Vec. Из векторов составляется словарь. Размер векторного представления – 200.

Архитектура плагина

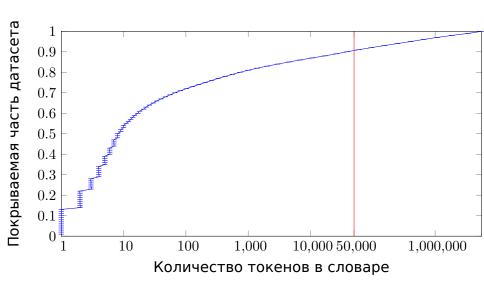


Датасет

150k Python Dataset1

- Не содержит дубликатов файлов
- Не содержит обфусцированный код
- Для кода из каждого файла из датасета возможно построить AST с помощью одного из существующих инструментов для Python

Словарь идентификаторов



Модели

Для обучения было использовано указанное количество фрагментов кода:

Детектор	Количество данных		
детектор		Валидация	
Детектор неправильных операторов в бинарных выражениях Детектор неправильных операндов в бинарных выражениях	3677456 3675316	1834956 1815835	
Детектор неправильного порядка аргументов в вызовах функций	1181396	568409	

Получены модели-детекторы, имеющие следующие точности:

Детектор	Точность
Детектор неправильных операторов в бинарных выражениях	92.08%
Детектор неправильных операндов в бинарных выражениях	85.29%
Детектор неправильного порядка аргументов в вызовах функций	92.06%

Апробация

Детектор	Всего найдено	Ошибки	Code quality issues	False positives
Детектор неправильных операторов	31	9	14	8
в бинарных выражениях	31	3		
Детектор неправильных операндов	20	5	10	5
в бинарных выражениях	20	,	10	5
Детектор неправильного порядка	25	4	15	6
аргументов в вызовах функций	23	7	13	0
Всего	76	18	39	19

Результаты

- Реализован набор инструментов для предобработки данных из датасета на Python
- Реализованы плагины для WebStorm и PyCharm, поддерживающие три инспекции кода:
 - Детектор неправильных бинарных операторов
 - Детектор неправильных операндов в бинарных выражениях
 - Детектор неправильного порядка аргументов в вызовах функций (для функций с двумя параметрами)

Результаты

- Реализация инструментария для предобработки данных:
 - https://github.com/ml-in-programming/DeepBugs
- Реализация плагинов: https://github.com/ml-in-programming/DeepBugsPlugin
- Плагин для PyCharm: https://plugins.jetbrains.com/plugin/ 12218-deepbugspython
- Плагин для WebStorm: https://plugins.jetbrains.com/plugin/ 12220-deepbugsjavascript